


# **Lecture2 - Image Classification**

### **▼ Image Classification**

- Computer Vision에서 Image Classification은 매우 핵심적이고 근본적인 작업임.
- 그러나 컴퓨터는 모든 것을 숫자로 인식하기 때문에 사람이 직관적으로 인식하는 것과 차이가 있는데, 이를 Semantic Gap 이라함.
- 컴퓨터에서 이미지는 기본적으로 0 ~ 255 사이의 pixel로 표현되며, 3개의 channel(RGB)의 matrix형태로 표현됩니다.

# **▼** Image Classification application

### Medical Imaging



Levy et al, 2016

# **Galaxy Classification**



Dieleman et al, 2014

From left to o gift: public domain by NASA, usage permitted in 150/74/1116, gub ic domain by NASA, and public domain

# Whale recognition



Kaggle Challenge

This image by Christin Dian is in the public derivational and structure from the U.S. NOAA.

# **▼** Object detection


• Object detection에서는 이미지를 classification (분류) 하는 것 뿐만 아니라 객체라고 판단되는 곳에 직사각형을 그려주는 localization을 해주는 작업

# Classification




CAT


# **Object Detection**



CAT, DOG, DUCK




• 방법 → classifiy different <mark>subregion</mark>



## **▼** <u>Image captioning</u>

• Image Captioning은 말 그대로 이미지의 캡션을 달아주는 일, 즉 **이미지를 보고** 어떤 이미지인지 언어로 설명하는 작업임.



- Image Captioning의 접근 방식은 크게 'Top-Down Approach'와 'Bottom-Up Approach'로 구분된다.
- Top-Down Approach에서는 이미지를 통째로 시스템에 통과 시켜서 얻은 '요점'을 언어로 변환하는 반면 Bottom-Up Approach에서는 이미지의 다양한 부분들로부터 단어들을 도출해내고, 이를 결합하여 문장을 얻어냄.
- 현재 가장 많이 쓰이고 있는 접근 방식은 Top-Down Approach인데, 그 이유는 Recurrent Neural Network(RNN)를 이용하여 각 Parameter들을 Train Data로부터 학습시킬 수 있으며, 이 방식의 성능이 가장 좋다고 평가 받기 때문임.
- 하지만, 이러한 Top-Down Approach은 이미지의 디테일한 부분들에 집중하는 것이 상대적으로 어렵다는 단점이 있으며 Bottom-Up Approach는 이미지의 모든 부분으로부터 하나씩 뽑아낸 단어들을 조합하기 때문에 디테일에까지 신경을 써줄 수 있음.

# **▼** Challenges


- ViewPoint Variation
  - 。 카메라가 움직일 때마다 pixels이 변화하는 문제


#### • Intraclass Variation

#### intra-/inter-class variaion

■ Intra-class variaion : class 내부의 분산이 어떠한가

■ Inter-class variaion : class 간 분산이 어떠한가





# • Fine-Grained Categories

。 비슷한 class 사이에서 classification을 해야함



### • Background Variation

。 배경으로 인해 object detection이 어려움



#### • illumination Variation

。 빛과 그림자의 영향으로 classification이 어려움



#### • Deformation

같은 Category 라도 different pose or position으로 인해 classification이 어려움




#### Occulsion

• 우리가 classify 하려는 object가 숨어있음



## **▼** Data-driven approach

이런 숫자로부터 우리는 '이 사진이 고양이다'라는 의미를 추출해 내고 싶은 게 목적이지만 빛(illumination Variation), 변형(Deformation), 보호색(Background Variation) 등 많은 Hurdle이 존재하기에, 명백한 방법이 없었음.



- 가장자리 모서리를 따라 outline을 만들어내며 추출하는 시도들이 있었지만 쉽지 않음. 그래서 고안된 방법이 Data에 기반한 접근법(Data-driven approach)임.
- Data-driven approach


- 1. Collect a dataset of images and labels
- 2. Use Machine Learning to train a classifier
- 3. Evaluate the classifier on new images

#### MNIST Data



- Drosophila of computer vision
  - 연구자들이 초파리로 처음 연구를 해보는 것을 의미
  - 너무 간단한 data set이라 좋은 성능이 나오므로 결과를 맹신하지 말고 아이디어의 검증 용도로만 사용 해야함
  - 10 classes & 50k training images & 10k test images

#### • CIFAR10



- 10 classes & 50k training images & 10k test images
- + 32 x 32 RGB Images

#### ImageNet



#### Gold Standard

- 。 높은 정확도를 보이는 상위 5개 알고리즘이 예측한 5개 labels 중 하나로 classify
- 1000 classes & 1.3M training images & 50k validation images (50 per class) & 100k test images (100 per class)

- Images have variable size, but often resized to 256x256 for training
- MIT Places




- focus on scene category
- 365 classes of different scene types & 8M training images & 18.25k
   validation images (50 per class) & 328.5k test images (900 per class)
- Images have variable size, but often resized to 256x256 for training
- Number of Training Pixels
  - ImageNet Data set is qualitively different and convincing data set but computationally expensive
  - CIFAR 100 is middle ground
  - Data set size trend is getting bigger

# **▼** Nearest Neighbor

- Implement ML algorithm, we need to implement train & predict function
  - Train func : Memorize all data and label
  - Predict fun: Predict the label of the most similar training image
    - 2개 이미지의 유사도를 계산하는 함수가 필요
- ▼ L1 distance vs L2 distance


# L1 (Manhattan) distance

$$d_1(I_1,I_2) = \sum_p |I_1^p - I_2^p|$$



# L2 (Euclidean) distance

$$d_2(I_1,I_2) = \sqrt{\sum_p \left(I_1^p - I_2^p\right)^2}$$



- L1 distance : 각 pixel값의 차이를 구한 후 결괏값을 합산하는 방법
  - 이는 Least Absolute Deviations(LAD), Least Absolute Errors(LAE),
     Least Absolute Value(LAV), Least Absolute Residual(LAR) 등으로도 불림.
  - L1 Loss는 L2 Loss에 비해 이상치(Outlier)의 영향을 덜 받는, Robust한 특성을 가집니만, 0에서 미분이 불가능함.
- L2 distance : 각 pixel값의 차이를 제곱한 후 root를 씌운 후 결괏값을 합산하는 방법
  - 。 이는 Least Squares Error(LSE, 최소자승법)로도 불림.
  - 이는 두 개 값의 절대값을 계산하던 L1 Loss와는 달리 L2 Loss는 제곱을 취하기에, 이상치가 들어오면 오차가 제곱이 되어 이상치에 더 영향을 받습니다. 때문에 이상치가 있는 경우에는 적용하기 힘든 방법론임.
  - Outlier point가 실제 데이터와 비교적 비슷한 위치에 존재할 때, 영향을 L1
     Loss에 비해 덜 받는 일관적인 예측을 할 수 있는 Stable한 특성을 가짐.

#### **▼ Nearest Neighbor Classifier**

```
class NearestNeibor :
    def __init__(self) :
        pass

## Memorize training data
    def train(self , X , y) :
        # X is N x D where each row is an examples. y is label which is 1-dim
        # of size N

self.Xtr = X
self.ytr = y
```

```
def predict(self , X) :


# X is N x D where each row is an example we wish to predict label for
num_test = X.shape(0)
Ypred = np.zeros(num_test, dtype = self.ytr.dtype)

## For each test image
## : Find nearest training image & Return label of nearest image
for i in xrange(num_test)
# find the nearest training images to the ith test image
# using the L1 distance (sum of absolute value difference)
distances = np.sum(np.abs(sel.Xtr - X[i,:]) , axis = 1)

# get the index with smallest distance
min_index = np.argmin(distances)

# predict the label of nearest example
Ypred[i] = self.ytr[min_index]
```


- Q.1 With N examples, how fast is training?
  - o constant (1)
  - o just store pointer
- Q.2 With N examples, how fast is testing?
  - linear time (N)
  - folding the size of the image and computation
  - need to compart it to each of the n training example
  - 실제에 적용하기 위해서는 training이 오래 걸려도 testing이 빨라야하므로 좋지 않은 방법임




• 그러나 Distance Metric만 있으면 어떠한 타입의 데이터에나 적용할 수 있음



#### **▼** Decision Boundaries




• K의 변화




• Distance Metirc의 변화

# L1 (Manhattan) distance



# L2 (Euclidean) distance



L1 distance는 수직, 수평, 대각과 같이 boundary의 기울기가 한정적이므로 더 잘게 나누어짐

#### **▼** Hyperparameters

- What is the best value of **K** to use?
- What is the best distance metric to use?
- 1. Choose Hyperparameters that work best on the data

**Idea #1**: Choose hyperparameters that work best on the data

**BAD**: K = 1 always works perfectly on training data

Your Dataset

- K = 1로 설정했을 때 training data에 대해서는 당연히 100%를 예측하겠지만 이는 과적합 문제를 야기함
- 2. Split data into train and test, choose hyperparameters that work best on test data

**Idea #1**: Choose hyperparameters that work best on the data


**BAD**: K = 1 always works perfectly on training data

Your Dataset


**Idea #2**: Split data into **train** and **test**, choose hyperparameters that work best on test data

train test

- test data에 알고리즘을 한번 적용한 순간, idea를 pollute하여 새로운 데이터에 어떤 알고리즘이 적합한지 알 수 없음
- 3. Split data into train, validation, and test, choose Hyperparameters on validation and evaluate on test




4. Cross-Validation : Split data into folds, try each fold as validation and average the results




Useful for small datasets, but (unfortunately) not used too frequently in deep learning

#### **▼ Universal Approximation**

 As the number of training samples goes to infinity, nearest neighbor can represent any function





- But it causes Curse of Dimensionality
  - Curse of Dimensionality: For uniform coverage of space, number of training points needed grows exponentially with dimension

Number of possible Number of elementary particles 32x32 binary images: in the visible universe: (source)

 $2^{32\times32} \approx 10^{308} \approx 10^{97}$ 

- Very slow at test time
- Distance metrics on pixels are not informative

Original





