

DSL Seminar: MCMC (5)

Kyung-han Kim

Data Science Lab

February, 2023

- 4주차 과제 Feedback
- Frequentist vs. Bayesian
 - C.I. (Confidence Interval and Credible Interval)
- Bayes' Theorem
- Prior, Likelihood, and Posterior
 - Conjugate Prior (6주차)
- 베이지통계에서 MCMC 사용하기 (6주차)

Frequentist vs. Bayesian

- 현대 통계학의 주류는 빈도론자(Frequentist)파이며, 여러분이 알고 계시는 확률 또한 빈도론자의 정의 방식일 가능성이 큽니다.
- 빈도론자와 베이지안(Bayesian)은 확률을 다른 방식으로 정의합니다.
- Frequentist: 확률을 Long-run frequency로 정의함
 - 같은 사건을 매우 많이 반복했을 때, 해당 사건이 일어나는 비율
- Bayesian: 확률을 Degree of Belief로 정의함
 - 사건의 반복 횟수와 무관하게, 해당 사건이 발생할 것으로 생각되는 정도
- 믿음의 정도(Degree of belief)라는 말이 너무 주관적? 사실은 그렇지 않습니다!
- 여러분은 빈도론자인지, 베이지안인지 검증해 봅시다.

Self-Test: Are you Bayesian?

- 동전을 던졌을 때, 앞면이 나올 확률과 뒷면이 나올 확률이 같다고 합시다.
- Q1] 지금 이 동전을 던져서 앞면이 나올 확률은?
- Q2] 제가 세미나 시작 전에 던져 놓은 동전이 있습니다.
이 동전이 앞면일 확률은 얼마일까요?
- 잘 생각해 보시고, 채팅창에 답을 올려 주세요.
정답이 있는 질문은 아닙니다!

- 베이지안은 이미 고정된 것에도 확률을 부여할 수 있습니다!
- 고정되어 있더라도 우리가 그 값이 얼마인지 정확히 모른다면, **믿음의 정도**에 따라 확률을 부여할 수 있기 때문입니다.
- 빈도론자의 해석 방식으로는 0과 1 외의 확률을 부여할 수 없습니다. 수없이 반복하더라도 이미 고정되어 결과가 변하지 않기 때문입니다.
- 통계학에서 배우는 대표적인 고정된 (Fixed) 값으로는 모수 (Parameter)가 있습니다. - Unknown, but fixed constant.
- 즉, 베이지통계에서는 모수가 가질 수 있는 값에 확률을 부여할 수 있습니다! 다르게 말하면 **모수를 확률변수로 취급**합니다.
- 확률변수에는 확률분포가 있고, 그렇다면 우리는 모수가 따르는 확률분포를 정의해 줘야 합니다. (조금 뒤에 설명)

두 개의 C.I. - Confidence & Credible (1)

- 신뢰 구간 (Confidence Interval) 과 관련한 흔한 오해가 있습니다.
- 95% 신뢰 구간: 모수가 신뢰 구간 안에 위치할 확률이 95%? (X)
- 모수는 고정 (fixed) 이고, 신뢰 구간이 움직입니다!




Figure 1: Confidence Interval

두 개의 C.I. - Confidence & Credible (2)

- 베イズ통계에서는 신뢰 구간이 아닌 Credible Interval을 사용합니다.
- 베イズ통계에서는 모수가 확률변수이기 때문에, 모수도 값이 변할 수 있습니다.
- 95% Credible Interval을 구하면,
해당 구간 안에 모수가 위치할 확률이 0.95라고 말할 수 있습니다!
- cf] 95% Confidence Interval의 올바른 해석:
같은 방법으로 신뢰 구간을 여러 번 구하면,
그 구간들 중 95%가 모수를 포함한다.

- 베이즈 정리 (Bayes' Theorem)은 조건부확률과 관련된 정리이자, 베이즈 통계의 근간이 되는 중요한 정리입니다!

$$P(B|A) = \frac{P(B)P(A|B)}{P(A)}$$

- 여기에서 A 를 X 로 바꾸고, B 를 θ 로 바꾸면?

$$P(\theta|X) = \frac{P(\theta)P(X|\theta)}{P(X)} \propto P(\theta)P(X|\theta) = P(\theta)L(\theta|X)$$

- 위의 식을 꼭 기억하시기 바랍니다!

필요 배경 지식: Likelihood

- Likelihood(우도)는 수리통계학(2)에서 처음 소개되는 개념으로, pdf/pmf를 다른 관점에서 바라본 결과물로 생각할 수 있습니다.
- Ex] 지수분포의 pdf: $f(x) = f(x|\lambda) = \lambda e^{-\lambda x}$
- 특정 x 에서 pdf 값을 알기 위해서는 모수(λ) 값을 알아야만 합니다.
- 즉, pdf 값은 모수 값이 주어져 있을 때 어떤 확률변수가 특정 값을 가질 가능성으로 해석할 수 있습니다. 또한 pdf는 x 에 대한 함수입니다.
- 반면 Likelihood는 똑같은 식을 모수(λ)에 대한 함수로 보는 것입니다.
- Likelihood: 관측된 확률변수 값(=데이터)이 주어져 있을 때, 모수가 특정 값이었을 가능성!
- 관측치가 여러 개일 경우 그 값들을 모두 곱한 것을 Likelihood function (우도함수)라고 합니다.
- Likelihood Function: $L(\lambda|x) = \prod_{i=1}^n \lambda e^{-\lambda x_i}$
- pdf/pmf는 x 에 대한 함수, likelihood는 모수(λ)에 대한 함수!

베이지스통계의 기본 구조

- 앞서 베이지스정리에서 도출한 식을 다시 가져 옵시다.

$$P(\theta|X) = \frac{P(\theta)P(X|\theta)}{P(X)} \propto P(\theta)P(X|\theta)$$

- 여기에서 우리는 각각의 항을 이렇게 부릅니다:

$$\underbrace{P(\theta|X)}_{\text{Posterior}} \propto \underbrace{P(\theta)}_{\text{Prior}} \underbrace{P(X|\theta)}_{\text{Likelihood}}$$

- 통계학의 기본 목표는 **모수를 추정**하는 것입니다.
- 베이지스통계에서는 모수가 확률분포를 가지므로,
모수를 추정하기 위해서는 모수가 따르는 확률분포를 알아내야 합니다.
- 대전제: 우리의 목표는 모수의 확률분포 알아내기!

Prior, Likelihood, Posterior (1): Prior

- $$\underbrace{P(\theta|X)}_{\text{Posterior}} \propto \underbrace{P(\theta)}_{\text{Prior}} \underbrace{P(X|\theta)}_{\text{Likelihood}}$$
- $P(\theta)$: Prior (distribution) - 사전 분포
- 분석을 본격적으로 시작하기 전에 설정하는, 모수 θ 가 따를 것으로 생각되는 확률분포의 pdf 혹은 pmf입니다.
- Remind! 베이지통계에서 **모수는 확률변수 취급하기 때문에** 자연스럽게 확률분포를 가져야만 합니다.
- Prior는 연구자가 임의로 설정할 수 있지만, 해당 모수의 성질에 맞게끔 설정하는 것이 좋습니다.
 - Ex] $\theta > 0$: $\theta \sim \Gamma(a, b)$ / $0 \leq \theta \leq 1$: $\theta \sim \text{Beta}(a, b)$
- Prior는 Likelihood와 결합해서 Posterior가 됩니다!

Prior, Likelihood, Posterior (2): Likelihood

- $$\underbrace{P(\theta|X)}_{\text{Posterior}} \propto \underbrace{P(\theta)}_{\text{Prior}} \underbrace{P(X|\theta)}_{\text{Likelihood}}$$
- $P(X|\theta)$: Likelihood (function) - 우도 함수
- 이 식은 기본적으로는 X 의 pdf/pmf입니다.
그리고 pdf/pmf는 x 에 대한 함수입니다. (모수 값을 알아야 계산 가능)
- 하지만 실제 상황에서는 우리는 오히려 모수 (θ) 값을 모르고,
해당 모수를 이용해 정의된 확률분포에서 얻어진 X 를 알고 있습니다.
- 즉, X 가 주어진 상태에서 θ 를 알아내야 하는 상황이 되므로
우리는 이 식을 θ 에 대한 함수로 보기로 합니다.
- 그리고 그것이 Likelihood의 정의였습니다.
- 경우에 따라 Likelihood가 θ 에 대한 함수임을 강조하기 위해 $P(X|\theta)$ 가 아니라 $L(\theta|X)$ 라고 쓰기도 합니다. (저는 후자를 선호해요)

Prior, Likelihood, Posterior (3): Posterior

- $$\underbrace{P(\theta|X)}_{\text{Posterior}} \propto \underbrace{P(\theta)}_{\text{Prior}} \underbrace{P(X|\theta)}_{\text{Likelihood}}$$
- $P(\theta|X)$: Posterior (distribution): 사후 분포
- X , 즉 데이터가 주어져 있을 때 (given) 모수가 따르는 확률분포입니다.
- Prior에 Likelihood 값을 곱하면, 그 값이 Posterior에 비례합니다.
- 다시 말하면, 데이터 수집 전에 설정한 모수의 확률분포인 Prior가 데이터를 수집해 얻은 Likelihood 값을 통해 Update되면, 그것을 우리가 Posterior라고 부릅니다.
- 모수가 따르는 확률분포를 우리가 수집한 데이터로 수정해 얻은 새 분포!
- 사후분포는 사전분포의 영향도 받지만, 수집한 데이터 (likelihood)의 영향도 받습니다.
- 데이터를 더 많이 수집할수록 사전분포의 영향력이 약해집니다.
- Posterior distribution을 알아내는 것이 최종 목표입니다!

Prior, Likelihood, Posterior (4): Normalizing Constant

- 원래 $P(\theta|X) = \frac{P(\theta)P(X|\theta)}{P(X)}$ 였습니다.
- 분모의 $P(X)$ 는 뭐길래 계속 무시했을까요?
- $P(X)$ 는 별다른 역할을 하지 않고, 구하기도 어렵습니다.
- θ 가 포함되어 있지 않기 때문에 상수인데, 값을 구하기는 상당히 어려운 어떤 숫자입니다.
- 이 숫자는 Posterior의 전체 적분값이 1이 되도록 해 줍니다.
- 그런 의미에서 이 값을 Normalizing Constant라고 합니다.
- 실제 계산 과정에서는 주로 무시됩니다.
Metropolis-Hastings algorithm 상에서 의미가 없는 값이기 때문입니다.

$$\text{결론: (Posterior)} = \frac{(\text{Prior}) \times (\text{Likelihood})}{(\text{Normalizing Constant})} \propto (\text{Prior}) \times (\text{Likelihood})$$

- 베이지통계에서는 모수를 확률변수 취급한다!
그러므로 각각의 모수 별로 pdf/pmf가 존재한다.
- 연구자는 모수가 따를 것으로 생각되는 확률분포를 먼저 가정한다.
이것을 사전분포 (Prior Distribution)라고 한다.
사전분포는 데이터가 수집되면 수정된다.
- 수집된 데이터는 우도함수 (Likelihood Function)에 반영된다.
- 우리의 목표는 처음에 우리가 가정한 사전분포를,
수집된 데이터로 수정 (update)한 결과물인 새로운 모수의 확률분포이다.
- 이 새로운 확률분포를 사후분포 (Posterior Distribution)라고 한다.
- Posterior는 Prior와 Likelihood의 곱에 비례한다!
- Posterior는 두 함수의 곱이기 때문에 형태가 복잡한 경우가 많다.
- 형태가 복잡한 분포에서의 sampling?: **MCMC**!
- Posterior의 평균을 closed-form으로 구할 수 없기 때문에,
Metropolis-Hastings algorithm을 이용해 Posterior mean을 추정한다.

- Conjugate Prior
- Bayesian Regression
- Metropolis-Hastings algorithm and Bayesian Statistics