

DSL Seminar: MCMC (7)

Kyung-han Kim

Data Science Lab

February, 2023

- 6주차 과제 Feedback
- Gibbs Sampler
- Bayesian Regression with M-H algorithm

- Bayesian regression의 핵심은, 우리가 알아내고자 하는 모수인 회귀계수 (β_i)들과 σ^2 를 확률변수 취급하는 것입니다.

$$\{y_i\}_{i=1}^n | \beta_0, \beta_1, \sigma^2 \sim^{iid} N(\beta_0 + \beta_1 x_i, \sigma^2)$$

$$\beta_0 \sim N(\mu, \tau)$$

$$\beta_1 \sim N(\mu, \tau)$$

$$\sigma^2 \sim IG(a, b)$$

- Posterior는 Prior와 Likelihood의 곱에 비례하므로,
 $\pi(\beta_0, \beta_1, \sigma^2 | X, Y) \propto \prod_{i=1}^n L(\beta_0, \beta_1, \sigma^2 | X_i, Y_i) \times p(\beta_0)p(\beta_1)p(\sigma^2).$
- Likelihood: Normal, Beta Prior: Normal, σ^2 Prior: Inverse-Gamma
- 모든 parameter는 서로 독립이라고 가정합니다.

GLM (Generalized Linear Model)

- GLM은 선형회귀를 확장시킨 것입니다.
- 일반적인 선형회귀에서, $\mathbf{Y} = \mathbf{X}\beta + \epsilon$ 이고 $\epsilon \sim N(0, \sigma^2)$ 이므로, 종속변수의 평균인 $\mu(\mathbf{X}) = E[\mathbf{Y}|\mathbf{X}] = \mathbf{X}\beta$ 입니다.
- GLM은 Link function을 사용해 종속변수의 범위를 실수 전체에서 특정 범위로 제한합니다. 이는 \mathbf{Y} 가 따르는 확률분포를 정규분포 이외의 것으로 규정하기 위함입니다.
- 로지스틱 회귀에서는 $Y \sim \text{Bernoulli}(p)$, 포아송 회귀에서는 $Y \sim \text{Pois}(\lambda)$ 입니다.
- 단, $\mathbf{X}\beta$ 쪽에 함수를 씌우면 더 이상 linear regression이 아니기 때문에, 똑같은 효과더라도 반드시 $E[\mathbf{Y}|\mathbf{X}]$ 쪽에 Link function을 씌웁니다.

$$g(E[\mathbf{Y}|\mathbf{X}]) = \mathbf{X}\beta$$

- 로지스틱 회귀는 종속변수가 Binary(0 혹은 1)일 때 사용합니다.
즉, 종속변수 (Y)는 베르누이 분포를 따른다는 설정입니다.
- 만약 그렇다면, $E[Y|X] = \mu(X)$ 은 구간 $(0, 1)$ 사이에 위치해야 합니다.
($\mu(X)$ 가 베르누이 분포의 모수 자리에 들어가기 때문!)
- 이 때 Link function은 정의역이 $0 \sim 1$, 치역이 실수 전체인 함수여야 합니다. ($X\beta$ 의 범위는 여전히 실수 전체)
- 이 조건을 만족시키는 대표적인 함수가 logit function입니다.

$$\text{logit}(p) = \log \frac{p}{1-p}$$

- $Y|X \sim \text{Bernoulli}(\mu(X))$, \therefore if $R \sim \text{Bernoulli}(p)$, then $E[R] = p$
 $g(\mu(X)) = \text{logit}(\mu(X)) = \log \frac{\mu(X)}{1-\mu(X)} = X\beta$,
 $\mu(X) = \frac{\exp(X\beta)}{1+\exp(X\beta)}$ (로짓함수의 역함수 형태).

- 포아송 회귀는 종속변수가 음이 아닌 정수 ($0, 1, 2, \dots$) 일 때 사용합니다.
즉, 종속변수 (Y)는 포아송 분포를 따른다는 설정입니다.
- 만약 그렇다면, $E[Y|X] = \mu(X) > 0$ 이어야 합니다.
- 이 때 Link function은 정의역이 양의 실수, 치역이 실수 전체인 함수여야 합니다.
- 이 조건을 만족시키는 대표적인 함수가 로그함수입니다.
- $Y|X \sim \text{Pois}(\mu(X))$,
 $g(\mu(X)) = \log(\mu(X)) = X\beta$,
 $\mu(X) = \exp(X\beta)$.

- Bayesian GLM 역시 회귀계수에 확률분포를 가정합니다.

$$\pi(\beta_0, \beta_1 | X, Y) \propto L(\beta_0, \beta_1 | X, Y) p(\beta_0) p(\beta_1)$$

- Logistic Regression ($Y \sim \text{Bernoulli}(\mu(X))$):

$$L(\beta_0, \beta_1 | X, Y) = \prod_{i=1}^n \mu(X_i)^{Y_i} (1 - \mu(X_i))^{1 - Y_i}, \quad \mu(X_i) = \frac{\exp(X_i^T \beta)}{1 + \exp(X_i^T \beta)}$$
$$(X_i = (1, x_{1i}), \quad \beta = (\beta_0, \beta_1))$$

- Poisson Regression ($Y \sim \text{Pois}(\mu(X))$):

$$L(\beta_0, \beta_1 | X, Y) = \prod_{i=1}^n \frac{\mu(X_i)^{Y_i} \exp(-\mu(X_i))}{Y_i!}, \quad \mu(X_i) = \exp(X_i^T \beta)$$

- 추정하는 회귀계수의 개수에 따라 X_i 와 β 의 차원은 달라진다.
($X_i, \beta \in \mathbb{R}^p$)

Example] Bayesian Statistics HW3

In this assignment, we will implement MCMC algorithm for a Bayesian GLM as follows:

$$\mathbf{Y} \sim \text{Poisson}(\mu(\mathbf{X}))$$

$$\log(\mu(\mathbf{X})) = \mathbf{X}\beta$$

$$\beta_j \sim N(0, 10) \text{ for } j = 1, 2, 3, 4$$

1) Simulate the dataset as follows.

(a) Let $X_i \in \mathbb{R}^4$ be the predictors for i th observation. For $i = 1, \dots, 1000$, simulate $X_i \sim N(0, \mathbf{I})$ independently. Here \mathbf{I} is an identity matrix.

(b) For $i = 1, \dots, 1000$, simulate $Y_i \sim \text{Poisson}(\exp(X_i^T \beta))$ independently. Set the true regression coefficient value as $\beta = (0.5, -0.5, 0, 1)$.

2) Implement the MCMC algorithm using the simulated dataset in Problem 1). Here you should write down the code without using any packages.

Report the trace plots, density plots, 95% HPD intervals, posterior mean, acceptance probability, and effective sample size for all parameters.

Example] Bayesian Statistics HW3 (1)

1) Simulate the dataset as follows.

(a) Let $X_i \in \mathbb{R}^4$ be the predictors for i th observation. For $i = 1, \dots, 1000$, simulate $X_i \sim N(0, \mathbf{I})$ independently. Here \mathbf{I} is an identity matrix.

X_i follows multivariate normal distribution. However, its covariance matrix is an identity matrix. So, 1000 iid samples from $N_4(0, \mathbf{I})$ is equivalent with 4000 iid samples from univariate standard normal distribution.

Example] Bayesian Statistics HW3 (2)

1) Simulate the dataset as follows.

(b) For $i = 1, \dots, 1000$, simulate $Y_i \sim \text{Poisson}(\exp(X_i^T \beta))$ independently. Set the true regression coefficient value as $\beta = (0.5, -0.5, 0, 1)$.

Now, you have 1000×4 data matrix X . Let $\beta = (0.5, -0.5, 0, 1)$. Multiply them, and we can get $X^T \beta$ matrix (or vector), which has a size of 1000×1 . Then you can also easily get $\exp(X_i^T \beta)$.

Let $M = \exp(X^T \beta)$, then this means

$Y_1 \sim \text{Pois}(M_1)$, $Y_2 \sim \text{Pois}(M_2)$, and so on.

You can use for loop and rpois function in order to simulate $Y_1 \sim Y_{1000}$.

Example] Bayesian Statistics HW3 (3)

$$\mathbf{Y} \sim \text{Poisson}(\mu(\mathbf{X}))$$

$$\log(\mu(\mathbf{X})) = \mathbf{X}\beta$$

$$\beta_j \sim N(0, 10) \text{ for } j = 1, 2, 3, 4$$

2) Implement the MCMC algorithm using the simulated dataset.

Our goal is to find the posterior distribution of $\beta_1 \sim \beta_4$.

Let $\beta = (\beta_1, \beta_2, \beta_3, \beta_4)$. Now, the posterior distribution is,

$$\pi(\beta_1, \beta_2, \beta_3, \beta_4 | X, Y) \propto L(\beta_1, \beta_2, \beta_3, \beta_4 | X, Y) p(\beta_1) p(\beta_2) p(\beta_3) p(\beta_4)$$

$$\text{where } L(\beta) = \prod_{i=1}^n \frac{\mu(X_i)^{Y_i} \exp(-\mu(X_i))}{Y_i!}, \quad \mu(X_i) = \exp(X_i^T \beta)$$

We already have X, Y and β , so we can calculate the value.

Example] Bayesian Statistics HW3 (4)

Now, let's use the Metropolis-Hastings algorithm to find the posterior distribution of $\beta_1 \sim \beta_4$.

One-by-one update and All-at-once update are both possible, but I'm going to update regression coefficients one-by-one (in order to control the acceptance probability more easily).

After setting the initial value, $\beta_1^{(0)}, \beta_2^{(0)}, \beta_3^{(0)}, \beta_4^{(0)}$, update each regression coefficient as follows:

- 1) Generate $\beta_1' \sim N(\beta_1^{(t)}, \sigma_1^2)$. (Normal proposal)
- 2) Find $\log(\alpha) = \log(\pi(\beta_1', \beta_2^{(t)}, \beta_3^{(t)}, \beta_4^{(t)})) - \log(\pi(\beta_1^{(t)}, \beta_2^{(t)}, \beta_3^{(t)}, \beta_4^{(t)}))$.
Here, you can ignore the prior of $\beta_2, \beta_3, \beta_4$. (kernel)
- 3) Generate $U \sim U(0, 1)$, and compare $\log(U)$ and $\log(\alpha)$.
- 4) If $\log(U) < \log(\alpha)$, $\beta_1^{(t+1)} = \beta_1'$. Else, $\beta_1^{(t+1)} = \beta_1^{(t)}$.
- 5) Repeat 1) ~ 4) for β_2, β_3 , and β_4 .
- 6) Repeat 1) ~ 5) for some sufficient number of iterations.

- Gibbs Sampler는 특수한 형태의 Metropolis-Hastings algorithm입니다.
- 우리의 target distribution이 multivariate이면서, **fully conditional distribution**을 알아낼 수 있다면 사용할 수 있는 방법입니다.
- 즉, 앞서 예시에서처럼 target distribution π 가,
 $\pi(\beta_1, \beta_2, \beta_3, \beta_4 | X, Y)$ 처럼 다변량 함수로 주어져 있을 때,
그것들의 fully conditional distribution인
 $\pi(\beta_1 | \beta_2, \beta_3, \beta_4, X, Y)$, $\pi(\beta_2 | \beta_1, \beta_3, \beta_4, X, Y)$,
 $\pi(\beta_3 | \beta_1, \beta_2, \beta_4, X, Y)$, $\pi(\beta_4 | \beta_1, \beta_2, \beta_3, X, Y)$ 을 모두 찾아낼 수 있다면
이 함수들을 이용해 Gibbs sampler를 사용할 수 있습니다.
- Gibbs sampler의 장점은, acceptance rate가 1이라는 점입니다.
- 따라서 Gibbs sampler에서는 threshold value를 계산하는 단계나,
해당 값과 U 를 비교해 proposed value(x')를 사용할지 말지를 결정하는
단계도 필요가 없습니다.
- Gibbs sampler를 Gibbs sampling이라고 하기도 합니다.

Gibbs Sampler Algorithm

- 1 Initialize $t = 0$ and $\mathbf{X}_0 = (X_1^{(0)}, \dots, X_d^{(0)})$.
- 2 Sample in turn:

$$X_1^{(t+1)} \sim f_{1|-1}(x_1 | X_2^{(t)}, X_3^{(t)}, \dots, X_d^{(t)})$$

$$X_2^{(t+1)} \sim f_{2|-2}(x_2 | X_1^{(t+1)}, X_3^{(t)}, \dots, X_d^{(t)})$$

...

$$X_d^{(t+1)} \sim f_{d|-d}(x_d | X_1^{(t+1)}, X_2^{(t+1)}, \dots, X_{d-1}^{(t+1)})$$

- 3 Set $\mathbf{X}_{t+1} = (X_1^{(t+1)}, \dots, X_d^{(t+1)})$.
- 4 Set $t = t + 1$ and go to step 2.

Gibbs sampler의 acceptance rate가 항상 1인 이유

Let $x_o = (x_1, \dots, x_i, \dots, x_d)$, $x' = (x_1, \dots, x', \dots, x_d)$,

$$\text{and } q(x'|x_o) = \frac{1}{d} f_{i|-i}(x'|x_j, j \neq i) = \frac{1}{d} \frac{f(x')}{f(x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_d)}.$$

$$\text{Then, } \frac{f(x')q(x_o|x')}{f(x_o)q(x'|x_o)} = \frac{f(x') \frac{1}{d} \frac{f(x_o)}{f(x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_d)}}{f(x_o) \frac{1}{d} \frac{f(x')}{f(x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_d)}} = \frac{f(x')f(x_o)}{f(x_o)f(x')} = 1.$$

$$\text{Therefore, } \alpha = \min\left(\frac{f(x')q(x_o|x')}{f(x_o)q(x'|x_o)}, 1\right) = \min(1, 1) = 1.$$

위의 증명과정을 통해 Gibbs sampler는 Metropolis-Hastings algorithm의 특수한 경우라는 것과, Gibbs sampler는 항상 acceptance rate가 1임을 알 수 있습니다.

- Bayesian Statistics HW4 (Bayesian GLM - logistic regression)
- 21-2 Statistical Computing Final Exam (Gibbs Sampler)

8주차 일정?

- 원래대로라면 8주차는 3월 5일 (일) 오전 11시부터입니다.
- 단, 8주차는 새로운 내용을 학습하는 주차가 아니라 통계전산 기말고사를 최대한 시험과 비슷한 환경에서 경험해 보는 것을 목표로 하는 주차입니다. 따라서 가능한 한 대면으로 진행하고자 합니다.
- 3월 17일 이전에 대면으로 가능한 시간을 맞춰 보아요!